视频风格迁移评估 - 合成流程演示

结论状态: 探索性
日期: 2026-11-08
评估目标: 演示可复现的风格、内容与运动评估流程，并明确合成片段不能作为模型基准证据。

执行摘要

SSIM 结构相似度 ↑：模拟平衡方法 0.9290 对 模拟闪烁方法 0.8111（更优；n=3）。

LAB 调色板 W1 ↓：模拟平衡方法 9.0208 对 模拟闪烁方法 7.4201（较差；n=3）。

重映射 RMSE Δ1 ↓：模拟平衡方法 31.70 对 模拟闪烁方法 47.77（更优；n=3）。

光流端点误差 Δ1 ↓：模拟平衡方法 0.2438 对 模拟闪烁方法 0.5426（更优；n=3）。

运行时间 ↓：模拟平衡方法 18.80 对 模拟闪烁方法 15.00（较差；n=3）。

盲评 VLM 审查：模拟平衡方法的整体视觉质量均值最高（4.00/5，1 位审查者）；这是感知证据，不是基准真值。

最常见的视觉失败标签：细节损失（3 次）。

诊断性风格指标只衡量调色板对齐；纹理和笔触结论需要额外的感知证据。

证据完整性检查

检查项	结果	状态
有效配对案例	3	通过
方法数量	3	通过
盲评 VLM 记录	已提供	通过
论文级感知指标	未检测到	尚未建立
结论状态	探索性	需说明限制

LAB 调色板距离与 Farneback 光流是确定性诊断代理，不能替代 RAFT、LPIPS、CLIP、FID 或 ArtFID。

指标定义与设计动机

SSIM 结构相似度

可用性: 在本次运行中计算

```
SSIM(x,y) = ((2*mu_x*mu_y + C1)*(2*sigma_xy + C2)) / ((mu_x^2 + mu_y^2 + C1)*(sigma_x^2 + sigma_y^2 + C2))
```

设计动机: SSIM 比较局部亮度、对比度和结构，而不是原始像素误差。它适合检测几何和结构变化，但强风格化本身也会改变对比度与纹理。

解释与报告注意事项: 应将其视为内容诊断，而不是感知风格分数。

PSNR 峰值信噪比

可用性: 在本次运行中计算

```
PSNR = 10 * log10(MAX^2 / MSE)
```

设计动机: PSNR
将均方误差转换为对数尺度，提供快速、确定性的保真度诊断。它对全局颜色变化、压缩和分辨率差异较敏感。

解释与报告注意事项: 不能把 PSNR 的小幅变化直接解释为感知质量的等比例变化。

LPIPS 感知距离

可用性: 本次运行未提供；定义用于论文级扩展

```
LPIPS(x,y) = sum_l (1/(H_l*W_l)) * sum_hw ||w_l * (phi_l(x)_hw - phi_l(y)_hw)||^2
```

设计动机: LPIPS 比较归一化深层特征，通常比像素指标更符合人类感知相似性。在有固定 LPIPS
实现时，应优先作为内容保持证据。

解释与报告注意事项: 所有比较方法必须使用相同的网络、预处理和权重。

CLIP-F 内容语义相似度

可用性: 本次运行未提供；定义用于论文级扩展

```
CLIP-F(R,I) = 100 * cos(phi_I(R), phi_I(I))
```

设计动机: CLIP-F 衡量风格化帧与源帧是否保留相同的图像级语义。当外观变化较大时，它可以补充结构指标。

解释与报告注意事项: 图像级嵌入可能遗漏局部身份、边界和遮挡错误。

CLIP-I 风格图像相似度

可用性: 本次运行未提供；定义用于论文级扩展

```
CLIP-I(R,S) = 100 * cos(phi_I(R), phi_I(S))
```

设计动机: CLIP-I 提供对内容变化较稳健的全局信号，用于判断生成帧与风格参考是否位于相近的语义视觉空间。它只是风格证据的一部分，不能单独证明纹理迁移成功。

解释与报告注意事项: 应进行相对比较，并结合纹理特征或盲评审查。

FID 分布距离

可用性: 本次运行未提供；定义用于论文级扩展

```
FID = ||mu_s - mu_g||_2^2 + Tr(S_s + S_g - 2*(S_s*S_g)^(1/2))
```

设计动机: FID 比较 Inception
特征分布，因此能捕捉超出单图颜色统计的风格集合差异。它需要足够数量的参考和生成帧来估计分布。

解释与报告注意事项: 单张风格图不能构成有效的 FID 风格分布。必须记录图像数量、分辨率和预处理。

ArtFID 联合风格-内容距离

可用性: 本次运行未提供；定义用于论文级扩展

```
ArtFID = (1 + mean_i LPIPS(I_i,R_i)) * (1 + FID(R,S))
```

设计动机: ArtFID
将感知内容保持和风格分布距离结合为一个数值。乘积形式会让“一个因素改善、另一个因素退化”的方法暴露出来。

解释与报告注意事项: 除非 LPIPS 和 FID 分量遵循固定的引用实现，否则不要使用该指标。

LAB 调色板 W1

可用性: 在本次运行中计算

```
W1_c = sum_k |CDF_frame,c(k) - CDF_style,c(k)| / 255; PaletteW1 = 100 * mean_c W1_c
```

设计动机: 该低成本的诊断指标概括 LAB
颜色边缘分布的一致性，可在运行昂贵感知指标前发现全局着色和调色板不匹配。

解释与报告注意事项: 它不衡量笔触、纹理附着、构图或风格语义。

源光流重映射 RMSE

可用性: 在本次运行中计算

```
WarpRMSE_d = sqrt(sum_x M_t(x)*||R_t(x) - W(R_(t+d))(x)||_2^2 / sum_x M_t(x))
```

设计动机: 源视频光流提供预期运动。使用该光流将后续输出帧重映射回当前帧，可以将漂移和闪烁与正常场景运动分开，并屏蔽遮挡像素。

解释与报告注意事项: 结果会继承光流估计器的误差；Farneback 是诊断代理，不是 RAFT。

光流端点误差

可用性: 在本次运行中计算

```
EPE_d = (1/|Omega|) * sum_{x in Omega} ||F_R(x) - F_I(x)||_2
```

设计动机: EPE 衡量风格化是否改变帧间估计位移，可揭示静态图像难以发现的运动改变和传播失败。

解释与报告注意事项: 纹理变化可能产生虚假光流；所有方法必须使用相同估计器和遮挡处理。

光流场相关性

可用性: 在本次运行中计算

```
rho_d = corr(flatten(F_R), flatten(F_I))
```

设计动机: 相关性衡量运动方向的一致性，相比 EPE 更少受幅度影响。两者结合可以区分方向错误和位移尺度变化。

解释与报告注意事项: 这是一个全局概括，可能掩盖局部运动错误。

时序 LPIPS（tLP）

可用性: 本次运行未提供；定义用于论文级扩展

```
tLP = (1/(T-d)) * sum_t LPIPS(R_t, W(R_(t+d)))
```

设计动机: tLP 在重映射分析中用深层特征感知误差替代像素误差，使纹理和结构不稳定性比原始 L2 差值更容易被检测。

解释与报告注意事项: 必须使用固定的 LPIPS 网络并报告时间偏移。

CLIP 时序一致性

可用性: 本次运行未提供；定义用于论文级扩展

```
CLIP-CONS = 100 * cos(phi(R_t+1)-phi(R_t), phi(I_t+1)-phi(I_t))
```

设计动机: CLIP-CONS
检查相邻风格化帧的语义变化是否与源视频一致。当内容被强风格化时，它可以补充像素重映射指标。

解释与报告注意事项: 它衡量语义变化一致性，而不是空间对齐或闪烁。

去趋势亮度闪烁

可用性: 在本次运行中计算

```
F = sqrt((1/T) * sum_t (l_t - (a*t+b))^2), where l_t is frame mean luminance
```

设计动机:
去除线性亮度趋势可以区分合理的曝光变化和突发全局闪烁。该指标成本低，直接针对常见的视频风格迁移伪影。

解释与报告注意事项: 它忽略局部闪烁和纹理粘连，这些需要运动感知指标或视觉审查。

盲评 VLM 分数

可用性: 在本次运行中计算

```
S_d,m = (1/R) * sum_r (1/|C_valid|) * sum_c s_(r,c,m,d), s in {1,2,3,4,5}
```

设计动机: 该评分标准覆盖风格一致性、内容保持、时序稳定性、伪影控制和整体质量，能补充自动指标难以区分的纹理与运动故障。逐案例盲化方法标签可降低方法身份偏差。

解释与报告注意事项: VLM 判断是感知证据而非真实标签；应记录模型版本，并使用多个独立审查者支持论文级结论。

运行时间与峰值显存

可用性: 在本次运行中计算

Runtime_m = mean_c t_(c,m); PeakMemory_m = max_c peak_(c,m)

设计动机:
如果缺少部署成本，质量比较并不完整。平均运行时间反映预期延迟，最大峰值显存反映最差观测资源需求。

解释与报告注意事项: 必须在相同硬件、精度、分辨率和批设置下测量，并同时报告均值和峰值。

定量结果

风格迁移

指标	模拟平衡方法	模拟闪烁方法	模拟覆盖方法
LAB 调色板 W1 （越低越好）	9.0208 ± 0.5445	**7.4201 ± 0.5347**	8.0416 ± 0.9411
LAB 色度 W1 （越低越好）	3.1765 ± 1.3380	**1.8824 ± 1.0178**	4.6879 ± 0.4238

最优和次优均值分别以粗体和下划线标出。 有效片段数: balanced: 3; flicker: 3; overlay: 3.

内容保持

指标	模拟平衡方法	模拟闪烁方法	模拟覆盖方法
SSIM 结构相似度 （越高越好）	**0.9290 ± 0.0165**	0.8111 ± 0.0326	0.7153 ± 0.0149
PSNR 峰值信噪比 （越高越好）	**22.58 ± 0.9018**	17.54 ± 0.3337	14.90 ± 0.3931

最优和次优均值分别以粗体和下划线标出。 有效片段数: balanced: 3; flicker: 3; overlay: 3.

时序与运动

指标	模拟平衡方法	模拟闪烁方法	模拟覆盖方法
重映射 RMSE Δ1 （越低越好）	**31.70 ± 6.7038**	47.77 ± 10.70	63.87 ± 6.8744
重映射 RMSE Δ5 （越低越好）	**33.20 ± 5.2688**	46.18 ± 10.55	63.70 ± 7.5960
光流端点误差 Δ1 （越低越好）	0.2438 ± 0.0558	0.5426 ± 0.3239	**0.1874 ± 0.0547**
光流相关性 Δ1 （越高越好）	**0.4268 ± 0.2381**	0.2267 ± 0.0923	0.2662 ± 0.1339
亮度闪烁 （越低越好）	0.1035 ± 0.0619	12.43 ± 0.4689	**0.0822 ± 0.0217**

最优和次优均值分别以粗体和下划线标出。 有效片段数: balanced: 3; flicker: 3; overlay: 3.

计算成本

指标	模拟平衡方法	模拟闪烁方法	模拟覆盖方法
运行时间 （越低越好）	18.80 ± 0.4000	**15.00 ± 0.4000**	16.50 ± 0.4000
峰值 GPU 显存 （越低越好）	12.70 ± 0.0000	**9.8000 ± 0.0000**	10.40 ± 0.0000

最优和次优均值分别以粗体和下划线标出。 有效片段数: balanced: 3; flicker: 3; overlay: 3.

相对主基线的配对比较

指标	Δ（正差值支持主方法）	dz	95% CI	n
SSIM 结构相似度	0.1180	7.1536	—	3
LAB 调色板 W1	-1.6007	-15.05	—	3

指标	Δ（正差值支持主方法）	dz	95% CI	n
重映射 RMSE Δ1	16.08	3.9236	—	3
光流端点误差 Δ1	0.2988	1.0159	—	3
运行时间	-3.8000	n/a	—	3

盲评视觉审查

方法	风格一致性	内容保持	时序稳定性	伪影控制	整体视觉质量
模拟平衡方法	4.00/5	4.67/5	3.67/5	3.33/5	4.00/5
模拟闪烁方法	4.67/5	3.67/5	2.00/5	2.00/5	2.33/5
模拟覆盖方法	3.33/5	3.00/5	3.00/5	2.00/5	2.00/5

失败标签: 细节损失 (3), 纹理附着/粘连 (3), 闪烁 (3), 边缘重影 (2), 时序跳变 (2), 纹理漂移 (1), 几何融化 (1)

审查记录数: 1. 已评分案例/方法记录: 9. VLM 评分是感知证据，不是真实标签。

分析与讨论

风格保真度

现有指标总体上更支持 模拟闪烁方法。 已报告的诊断值为：LAB 调色板 W1 9.0208 ± 0.5445；LAB 色度 W1 3.1765 ± 1.3380。 盲评风格一致性为 4.00/5。

内容保持

现有指标总体上更支持 模拟平衡方法。 已报告的诊断值为：SSIM 结构相似度 0.9290 ± 0.0165；PSNR 峰值信噪比 22.58 ± 0.9018。

运动与时序稳定性

现有指标总体上更支持 模拟平衡方法。 已报告的诊断值为：重映射 RMSE Δ1 31.70 ± 6.7038；重映射 RMSE Δ5 33.20 ± 5.2688；光流端点误差 Δ1 0.2438 ± 0.0558；亮度闪烁 0.1035 ± 0.0619。

感知审查与失败模式

盲评中整体视觉质量最高的是 模拟平衡方法（4.00/5，1
位审查者）。该结果仅代表当前审查样本中的感知偏好，不等同于真实标签。
主要失败模式为细节损失（3）、纹理附着/粘连（3）、闪烁（3）。

计算成本

现有指标总体上更支持 模拟闪烁方法。 主方法的运行时间 18.80 ± 0.4000 秒、峰值显存 12.70 ± 0.0000 GB。

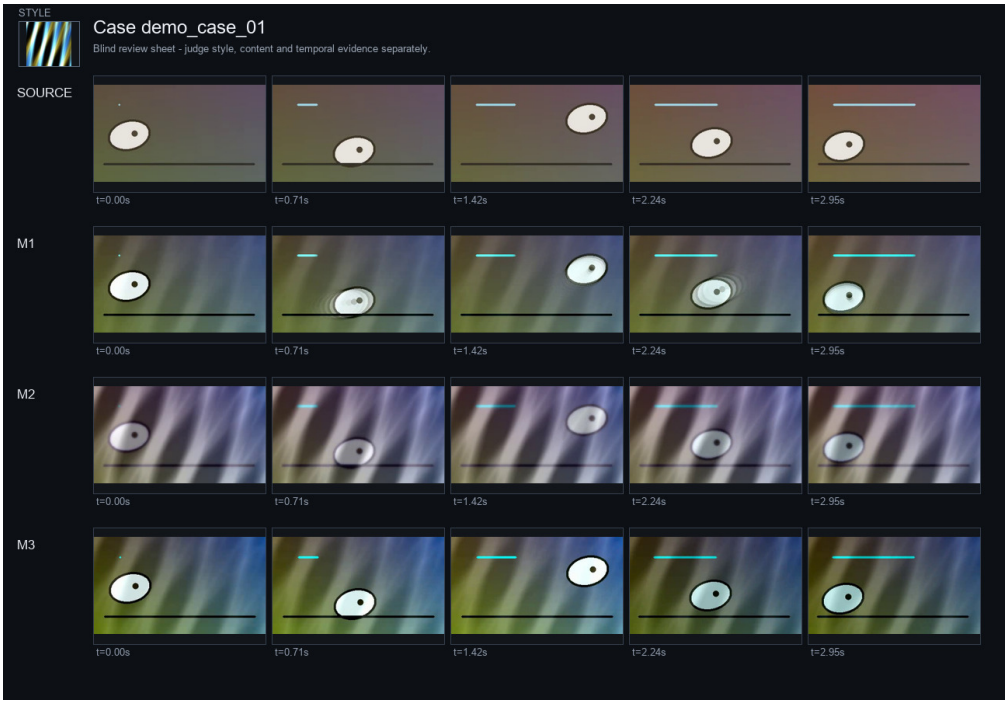
综合判断

结果呈现明显的多维权衡，没有方法在所有维度上占优；因此不能据此声称单一方法的普遍优越性。

单案例结果

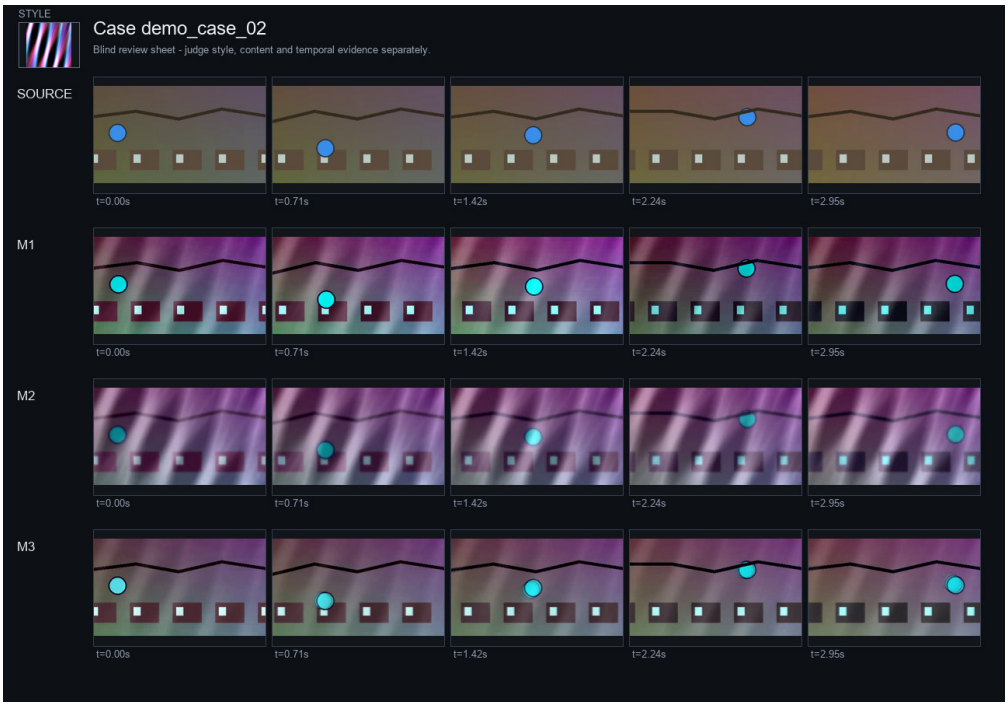
demo_case_01

方法	SSIM 越高越好	调色板 W1 越低越好	重映射 RMSE Δ1 越低越好	光流 EPE Δ1 越低越好
模拟平衡方法	0.9395	8.8136	28.61	0.2963
模拟闪烁方法	0.8270	7.3344	44.06	0.5494
模拟覆盖方法	0.7122	8.1708	65.43	0.1389



demo_case_02

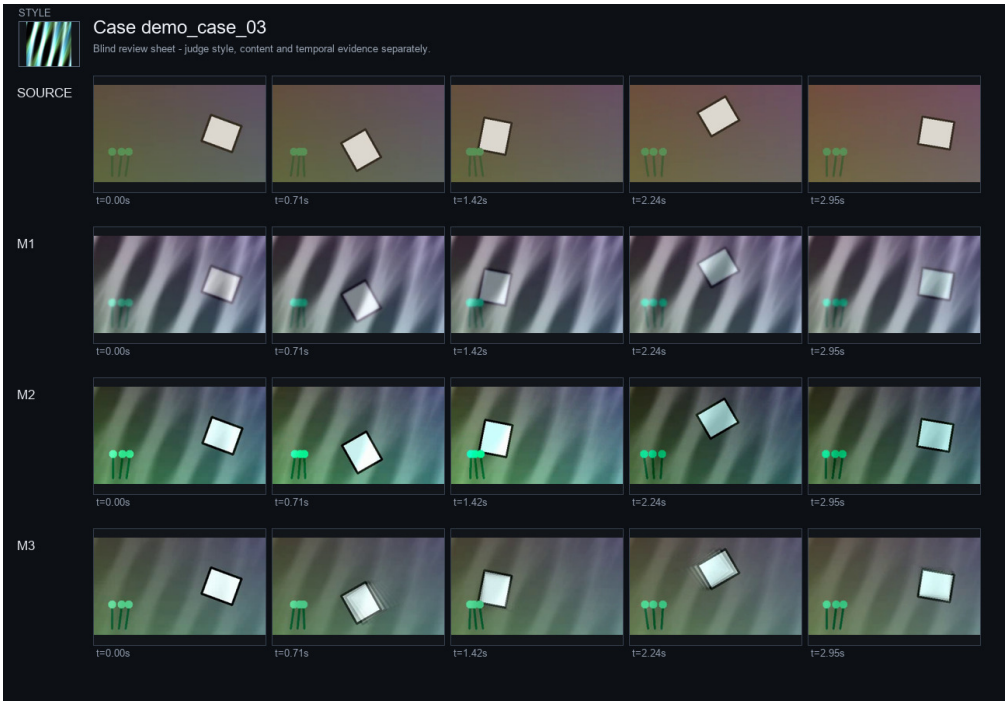
方法	SSIM 越高越好	调色板 W1 越低越好	重映射 RMSE Δ1 越低越好	光流 EPE Δ1 越低越好
模拟平衡方法	0.9101	8.6103	39.39	0.2500
模拟闪烁方法	0.7736	6.9334	59.84	0.8630
模拟覆盖方法	0.7315	7.0425	69.83	0.2467



demo_case_03

方法	SSIM 越高越好	调色板 W1 越低越好	重映射 RMSE Δ1 越低越好	光流 EPE Δ1 越低越好
模拟平衡方法	0.9376	9.6385	27.09	0.1852

方法	SSIM 越高越好	调色板 W1 越低越好	重映射 RMSE Δ1 越低越好	光流 EPE Δ1 越低越好
模拟闪烁方法	0.8327	7.9925	39.42	0.2154
模拟覆盖方法	0.7022	8.9114	56.35	0.1766



有效性威胁

- 内容与风格的数据分布可能不能代表实际使用场景。
- 低层指标容易受全局着色和压缩影响。
- Farneback 光流不是 RAFT，在大运动或遮挡条件下可能失效。
- 单张风格图不能构成有效的 FID 风格分布。
- VLM 审查可能受到位置、内容和提示词偏差影响。
- 直接引用论文的外部基线数值可能没有统一推理设置。
- 少于五个片段时，比较置信区间不稳定。

结论与建议

本报告用 3
个合成案例验证了评估流程，未提供真实模型性能证据。结果表、感知分析和结论仍保留多维证据，不应被解释为 EchoStyle 或本文方法的基准排名。

下一步建议

请使用当前结果验证评估流程并设计下一组实验。不要把这个合成演示作为模型性能证据。